REDES NEURAIS

Métodos otimizados para treinamento das redes MLP e regularização

TÓPICOS

1. ALGORITMOS OTIMIZADOS
    1. RMSPROP
    2. Adam

2. REGULARIZAÇÃO
    1. L2 e L1
    2. Dropout

ALGORITMOS OTIMIZADOS

- Não possuímos informação completa sobre a função de erro
- Dificuldades para encontrar (configurar) uma taxa de aprendizagem adequada
  - Mínimo local em E
  - Plateaus
  - Oscilações
- As adaptações são realizadas em função da derivada parcial do erro quadrático médio

ALGORITMOS OTIMIZADOS

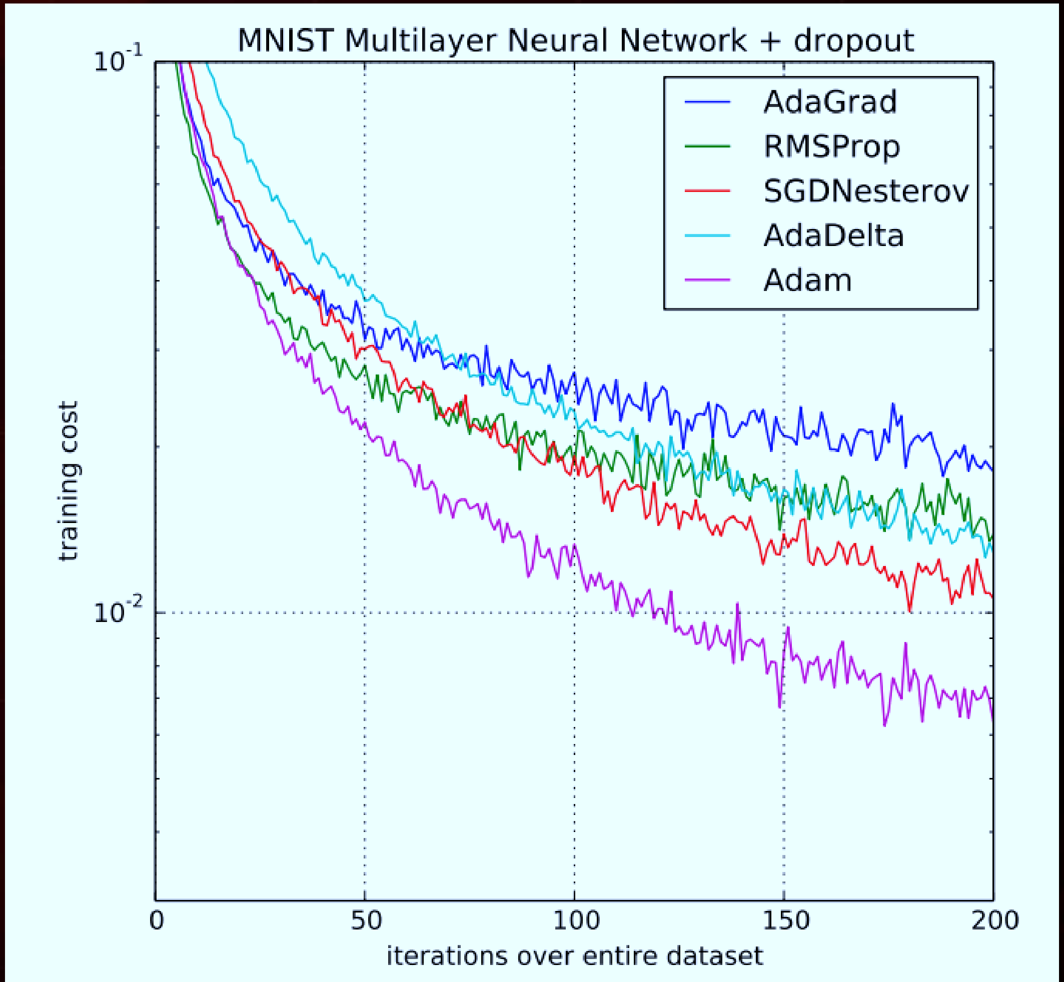

Fonte: https://arxiv.org/abs/1412.6980

1. Diversos algoritmos propostos na literatura
   1. RProp
   2. AdaGrad
   3. RMSProp
   4. Adam
   5. Etc.

ALGORITMOS OTIMIZADOS

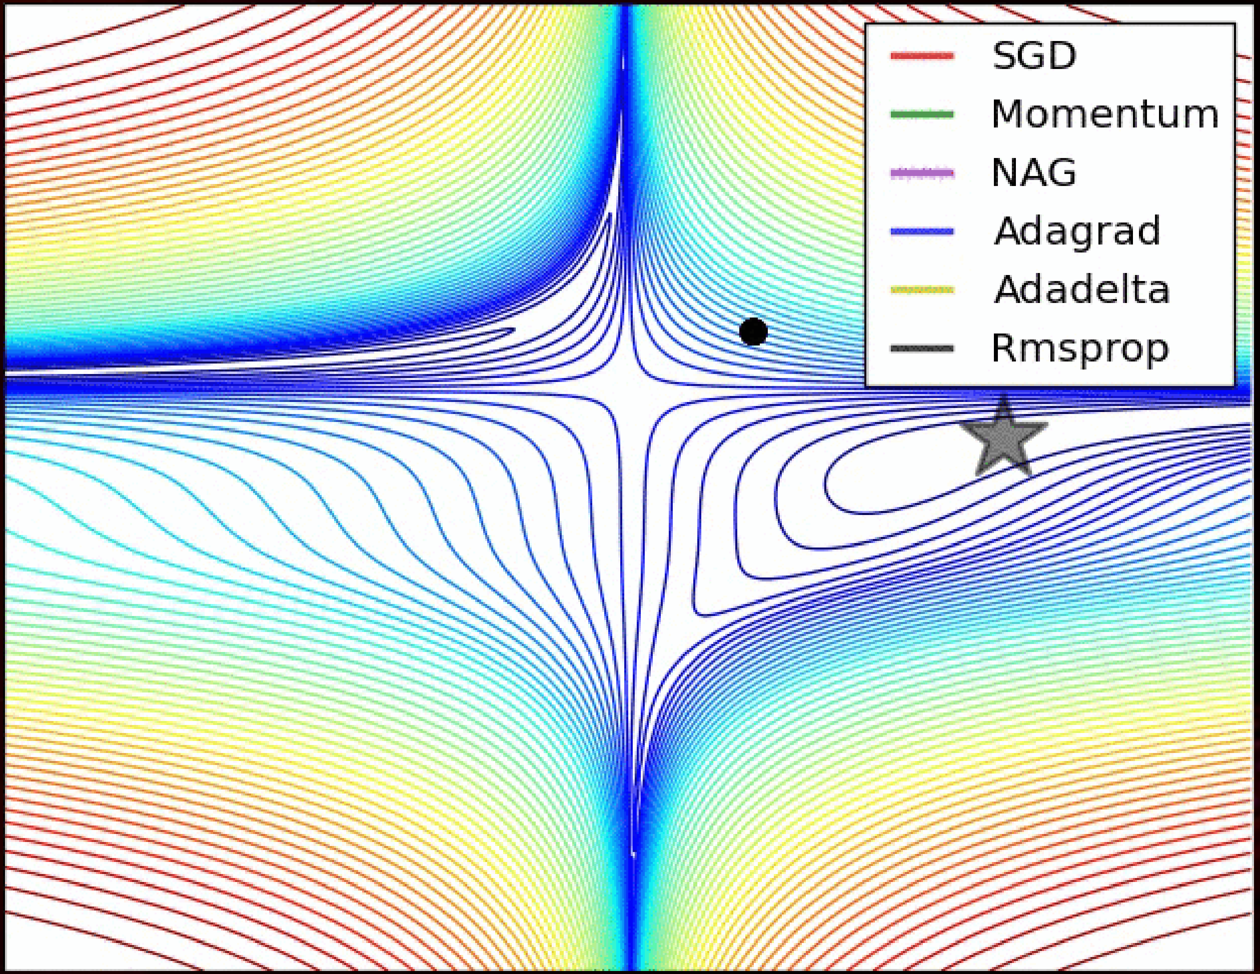

Fonte: https://ml-cheatsheet.readthedocs.io/en/latest/optimizers.html

RMSProp

- **R**oot **M**ean **S**quared **Prop**agation **(RMSProp)**
- **Proposto por Geoffrey Hinton (não-publicado formalmente)**
- **Calcula a média móvel dos gradientes para cada peso ao longo do treinamento**
- **Utiliza esse valor para ajustar a atualização**
  - **Grandes variações reduzem atualização**
  - **Pequenas variações amplificam a atualização**

RMSProp

Referência:
https://www.cs.toronto.edu/~tijmen/csc321/slides/lecture_slides_lec6.pdf

$$S_w^t = \beta S_w^{t-1} + (1-\beta)\left(\frac{\partial E}{\partial w}\right)^2$$

$$\Delta w = -\frac{\eta}{\sqrt{S_w}}\frac{\partial E}{\partial w}$$

Parâmetros do algoritmo:

beta = 0,99 (padrão)

Adam

- **Adaptive Moment Estimation**
- **Proposto por Kingma & Ba (2014)**
- **Consiste numa extensão do RMSProp adicionando o termo de momentum**

Referência:
https://arxiv.org/abs/1412.6980

Adam

$$M_w^t = \beta_1 M_w^{t-1} + (1 - \beta 1)\left(\frac{\partial E}{\partial w}\right)$$

$$S_w^t = \beta_2 S_w^{t-1} + (1 - \beta 2)\left(\frac{\partial E}{\partial w}\right)^2$$

PARÂMETROS DO ALGORITMO

- **beta1 = 0,9 (momentum)**
- **beta2 = 0,999 (média móvel dos gradientes^2)**

$$\delta w = -\frac{\eta}{\sqrt{s_w}} M_w$$

REGULARIZAÇÃO

- Tem como objetivo central reduzir a “flexibilidade” do modelo e, como consequência, evitar o overfitting (sobreajuste)
  - Regularização L2 / L1
  - Dropout

REGULARIZAÇÃO L2

- **Estabelece um limite para os pesos evitando a super especialização ou saturação sináptica**

$$E = E_0 + \frac{\lambda}{2n} \sum_w w^2$$

$$E = \frac{1}{2n} \sum_j (d_j - y_j)^2 + \frac{\lambda}{2n} \sum_w w^2$$

REGULARIZAÇÃO L2

O QUE A L2 FAZ?

- Reduz o tamanho dos pesos
- Por que isso ajuda com o overfitting?

$$v_k = \sum w_{kj} x_j$$

$$y_k = f(v_k)$$

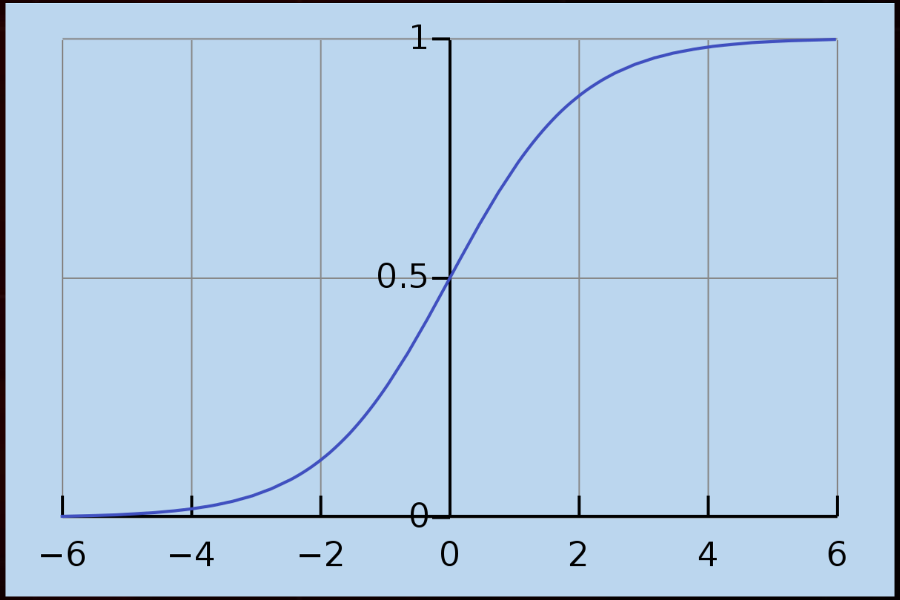

Fonte: https://en.wikipedia.org/wiki/Logistic_function

REGULARIZAÇÃO L1

- Semelhante à regularização L2, porém, considera a soma absoluta dos pesos ao invés da soma quadrática
- Como não há penalidade quadrática, alguns pesos podem assumir valores altos sem comprometer o custo
- Bastante utilizada para seleção de atributos

Dropout

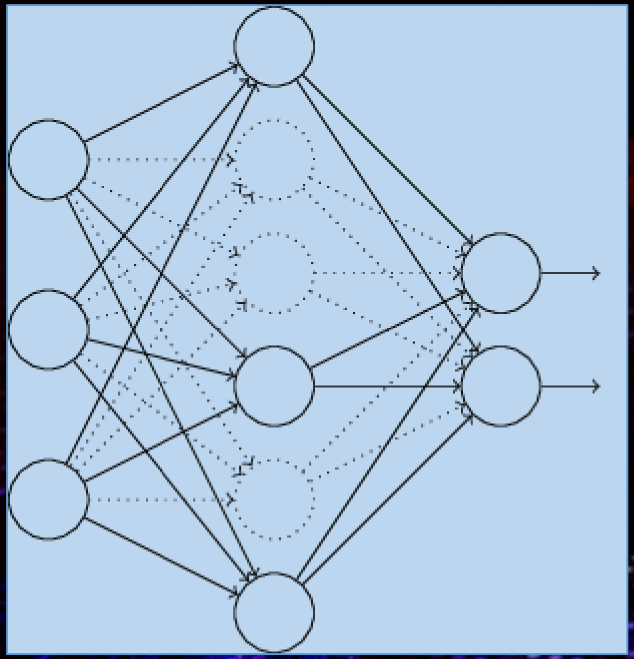

- Desativar algumas unidades durante o treinamento da rede
- Evita que um “único” neurônio decore o padrão
- A “carga” do exemplo é distribuída pelos pesos da rede
- Parâmetro: probabilidade de ativação das unidades
- Efeito prático similar à regularização L2

Fonte: https://www.deeplearningbook.com.br/capitulo-23-como-funciona-o-dropout/
Referência: https://arxiv.org/pdf/1207.0580.pdf

OUTRAS MELHORIAS

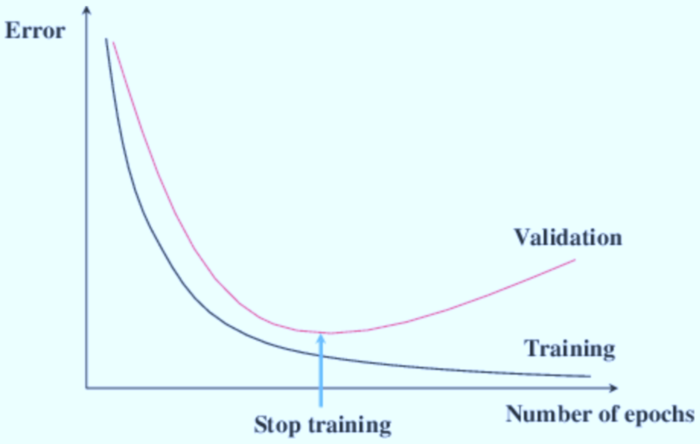

- Obter mais dados representativos
- Aumento artificial de dados (data augmentation)
- Parada prematura do treinamento
- Adequação da função de custo (loss)
  - Diversas funções disponíveis na literatura
  - https://pytorch.org/docs/stable/nn.html#loss-functions
  - Funções adequadas para problemas específicos

O QUE VIMOS?

- Conhecemos alguns algoritmos otimizados para treinamento da rede MLP
- Entendemos o conceito de regularização

PRÓXIMA VIDEOAULA

- Realizaremos experimentos práticos com a rede MLP

ATÉ A PRÓXIMA!!